

レポート提出票

科目名: 応用情報工学実験

実験課題名: 寒水研究室 第二回

実施日: 2025年 9月 27日

学籍番号: 4623044

氏名: 呉 子吟

共同実験者:

_____	_____
_____	_____
_____	_____
_____	_____

1 演習1：外れ値の削除

- 実験中で外れ値があることが分かるため、外れ値をデータから削除して、もう一度回帰分析を実行してください
 - － 説明変数は mreg2 と同じで良い
- 報告事項
 - － Rコード
 - － 結果
 - － mreg2 と比較した場合の考察

1.1 結果

付録の1~33行目のRコード実行し、以下のような結果が得られた。

```
1 > summary(mreg1)
2 Call:
3 lm(formula = WT18 ~ ., data = BGSg)
4
5 Residuals:
6      Min       1Q   Median       3Q      Max
7 -13.595  -3.388  -1.019   2.590  30.837
8
9 Coefficients:
10              Estimate Std. Error t value Pr(>|t|)
11 (Intercept) -22.2784    22.3957  -0.995   0.3235
12 HT9          -0.1633     0.3176  -0.514   0.6089
13 WT9           0.9460     0.1994   4.744 1.16e-05 ***
14 HT18          0.4456     0.2225   2.003   0.0493 *
15 ---
16 Signif. codes:
17 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
18
19 Residual standard error: 6.065 on 66 degrees of freedom
20 Multiple R-squared:  0.5312, Adjusted R-squared:  0.5099
21 F-statistic: 24.93 on 3 and 66 DF, p-value: 6.697e-11
22
23
24 > summary(mreg2)
25 Call:
26 lm(formula = WT18 ~ WT9 + HT18, data = BGSg)
27
28 Residuals:
29      Min       1Q   Median       3Q      Max
30 -14.094  -3.185  -1.109   2.591  30.711
31
32 Coefficients:
33              Estimate Std. Error t value Pr(>|t|)
34 (Intercept) -26.7286    20.5419  -1.301   0.1977
35 WT9           0.8723     0.1378   6.330 2.35e-08 ***
36 HT18          0.3538     0.1321   2.678   0.0093 **
37 ---
38 Signif. codes:
```

```

39 0 '***' 0.001 '**' 0.01 '*' 0.05 ' ' 0.1 ' ' 1
40
41 Residual standard error: 6.032 on 67 degrees of freedom
42 Multiple R-squared: 0.5294, Adjusted R-squared: 0.5153
43 F-statistic: 37.68 on 2 and 67 DF, p-value: 1.083e-11

```




図 1: 削除前の plot

実験中の回帰診断プロット図1のように示される, 明らかに外れ値が存在することが確認された. ここで, "134"というデータが外れ値として回帰直線の推定に大きな影響を与える可能性があるため, 一個の"134"データのみ削除し, 再度回帰分析を実行した. Rコードは以下のよう示す.

```

1 #演習1
2 #外れ値を削除
3 BGSg[rownames(BGSg) == "134", ]
4 BGSg2 <- BGSg[rownames(BGSg) != "134", ]
5 #もう一度分析
6 #2
7 mreg2_new <- lm(WT18 ~ WT9 + HT18, data = BGSg2)
8 summary(mreg2_new)

```




図 2: 削除後の plot

```

1 > summary(mreg2_new)
2
3 Call:
4 lm(formula = WT18 ~ WT9 + HT18, data = BGSg2)
5
6 Residuals:
7     Min       1Q   Median       3Q      Max
8 -10.5104  -2.9654  -0.1529   2.6130  14.2616
9
10 Coefficients:
11             Estimate Std. Error t value Pr(>|t|)
12 (Intercept) -42.6673    15.8792  -2.687  0.00911 **
13 WT9           0.6738     0.1092   6.171 4.68e-08 ***
14 HT18          0.4843     0.1028   4.712 1.31e-05 ***
15 ---
16 Signif. codes:
17 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
18
19 Residual standard error: 4.614 on 66 degrees of freedom
20 Multiple R-squared:  0.6224, Adjusted R-squared:  0.611
21 F-statistic: 54.39 on 2 and 66 DF, p-value: 1.102e-14

```

1.2 考察

削除後，上記のデータと図 2 が得られた。図 2 により，残差値のプロットでは，大きな外れ値がなくなり，赤い線も水平に近づき，残差が 0 を中心にランダムに散布するようになった。

また、Q-Q Residuals プロットも、残差分布が理論直線 ($y = x$) のような形に近づいた。これにより残差の正規性が改善される。最後、標準化残差の絶対値の平方根のプロットでは、残差の分散が大体全体的に均一化されている。最後に、てこ比と Cook の距離プロットにおいても、外れ値“134”の影響が解消された。これにより、モデルが個々の観測値に過度に依存することなく、より安定した推定が可能と考える。

削除前後の変化を比べると、summary(mreg2_new) の結果により、外れ値 (134 番) を削除する後では残差の SE は 6.032 から 4.614 に減り、調整後の決定係数 $Adjusted_R^2$ は 0.5153 か 0.611 へ上がり、モデルの予測精度が向上したことが分かった。自由度については、削除により観測値の個数が 70 から 69 に減少したため、残差自由度が 67 から 66 へと 1 減少した。回帰変数の係数については、WT9 の推定値は 0.8723 から 0.6738 に減少し、HT18 の推定値は 0.3538 から 0.4843 と増加した。Intercept と HT18 の値も向上し、推定の有意性が大幅に改善したことがわかる。

以上の結果から、外れ値を削除することで線形回帰モデルの適合度が改善し、統計的仮定（線形性・正規性・等分散性）がより成立していると結論づけられる。

2 演習 2：シミュレーション

- シミュレーション設定
 - $M = 10000$
 - 乱数シードは学籍番号の下二桁 (=44)
 - その他は同じ（変更可，その場合は設定を報告）
- 報告事項
 - R コード
 - 真値を含んだ信頼区間の割合
 - プロットはいらない

2.1 結果と考察

授業中で教えてくれたコードを添削し、 $M = 10000$ 、乱数シード=set.seed(44) (学籍番号:4623044) と設定した上、以下のような R コードを実行した。今演習のシミュレーションでは、繰り返し回数を $M = 10000$ と設定して図のみでは結果を判別することが困難であるため、コードにはカウンタ (count_in, count_out) を追加し、それぞれ「真の値を含む区間の回数」と「真の値を含まない区間の回数」を記録した、

```
1 #simulation2
2 M <- 10000
3 n <- 100
4 beta <- c(1, 2, -0.5)
5
6 ci.lower <- ci.upper <- rep(0,M)
7 plot(NULL, xlab="m", ylab="Confidence Interval", xlim=c(1,M), ylim=c(1,3))
8 set.seed(44)
```

```

9
10 ci.lower <- ci.upper <- rep(0, M)
11 count_in <- 0 # カウンタ：期待値含む
12 count_out <- 0 # カウンタ：期待値含まない
13
14 confint(mreg2)
15 for (m in 1:M) { # 文開始for
16   x1 <- runif(n, -3, 3)
17   x2 <- runif(n, -3, 3)
18   error <- rnorm(n, 0, sqrt(5))
19   y <- beta[1] + beta[2]*x1 + beta[3]*x2 + error
20   reg <- lm(y ~ x1 + x2)
21   ci.beta1 <- confint(reg)[2,]
22   ci.lower[m] <- ci.beta1[1]
23   ci.upper[m] <- ci.beta1[2]
24   if(ci.lower[m]>beta[2]|ci.upper[m]<beta[2]){
25     points(x=c(m,m), y=ci.beta1, pch=15, cex=0.5, col="red")
26     segments(x0=m, y0=ci.lower[m], x1=m, y1=ci.upper[m], col="red")
27     count_out <- count_out + 1
28   }else{
29     points(x=c(m,m), y=ci.beta1, pch=15, cex=0.5, col="blue")
30     segments(x0=m, y0=ci.lower[m], x1=m, y1=ci.upper[m], col="blue")
31     count_in <- count_in + 1
32   }
33 } # for
34 abline(h=2,lty=2)
35 cat("真の値を含む回数:", count_in, "\n")
36 cat("真の値を含まない回数:", count_out, "\n")
37 cat("被覆率:", count_in / M, "\n")

```

出力結果は以下のように示される。

```

1 > confint(mreg2)
2               2.5 %       97.5 %
3 (Intercept) -67.73049299 14.2733139
4 WT9          0.59721757  1.1473469
5 HT18         0.09012819  0.6175522
6
7 > cat("真の値を含む回数:", count_in, "\n")真の値を含む回数
8 : 9513
9 > cat("真の値を含まない回数:", count_out, "\n")真の値を含まない回数
10 : 487
11 > cat("被覆率:", count_in / M, "\n")被覆率
12 : 0.9513

```

出力結果により、 $M = 10000$ の繰り返しの中で、真の値を含む回数: 9513 , 真の値を含まない回数: 487 , 二つのデータの割合として理論的な値（真の値）を含む割合: 0.9513 が算出された、これにより、同じ母集団からの標本で信頼区間を構成する作業を、複数回繰り返したとき、母数が含まれている信頼区間が95%回であることがシミュレーションにより確認した。

付録

```
1 # パッケージのインストール (インストール alr4 包)
2 install.packages("alr4")
3
4 # パッケージの読み込み (alr4 包)
5 library(alr4)
6
7 # データの読み込み (BGSgirls)
8 data(BGSgirls)
9
10 # 今回必要なデータのみを残す (只保留需要的列)
11 BGSg <- subset(x = BGSgirls, select = c(HT9, WT9, HT18, WT18))
12
13
14 # ようやく統計量
15 summary(BGSg)
16
17 # 相関係数
18 cor(BGSg)
19
20 # 散布図行列
21 pairs(BGSg)
22
23 # 1
24 mreg1 <- lm(WT18 ~ ., data = BGSg)
25 summary(mreg1)
26
27 # 2
28 mreg2 <- lm(WT18 ~ WT9 + HT18, data = BGSg)
29 summary(mreg2)
30
31 par(mfrow=c(2,2))
32 plot(mreg2, which=c(1,2,3,5))
33 par(mfrow=c(1,1))
34
35
36 # 演習1
37 # 削除
38 BGSg[rownames(BGSg) == "134", ]
39 BGSg2 <- BGSg[rownames(BGSg) != "134", ]
40 # もう一度分析
41 # 2
42 mreg2_new <- lm(WT18 ~ WT9 + HT18, data = BGSg2)
43 summary(mreg2_new)
44
45 par(mfrow=c(2,2))
46 plot(mreg2_new, which=c(1,2,3,5))
47 par(mfrow=c(1,1))
48
49
50
51
52 y <- BGSgirls$WT18
53 x1 <- BGSgirls$HT18
54 x2 <- x3 <- x1
55 x2[1] <- x2[1] + 1
56 x3[1] <- x3[1] - 1
```

```

57 BGSnew <- data.frame(WT18=y, HT18=x1, x2=x2, x3=x3)
58 plot(x1, x2)
59 summary(lm(WT18 ~ HT18, data=BGSnew))
60 summary(lm(WT18 ~ HT18 + x2, data=BGSnew))
61 summary(lm(WT18 ~ HT18 + x3, data=BGSnew))
62
63
64 #
65 reg.x2 <- lm(WT18 ~ HT18 + x2, data=BGSnew)
66 reg.x3 <- lm(WT18 ~ HT18 + x3, data=BGSnew)
67 #VIF
68 library(car)
69 vif(reg.x2)
70 vif(reg.x3)
71
72 #simulation1
73 M <- 100
74 n <- 100
75 beta <- c(1, 2, -0.5)
76
77 ci.lower <- ci.upper <- rep(0,M)
78 plot(NULL, xlab="m", ylab="Confidence Interval", xlim=c(1,M), ylim=c(1,3))
79 set.seed(2)
80
81 confint(mreg2)
82 for (m in 1:M) { # 文開始for
83   x1 <- runif(n, -3, 3)
84   x2 <- runif(n, -3, 3)
85   error <- rnorm(n, 0, sqrt(5))
86   y <- beta[1] + beta[2]*x1 + beta[3]*x2 + error
87   reg <- lm(y ~ x1 + x2)
88   ci.beta1 <- confint(reg)[2,]
89   ci.lower[m] <- ci.beta1[1]
90   ci.upper[m] <- ci.beta1[2]
91   if(ci.lower[m]>beta[2]|ci.upper[m]<beta[2]){
92     points(x=c(m,m), y=ci.beta1, pch=15, cex=0.5, col="red")
93     segments(x0=m, y0=ci.lower[m], x1=m, y1=ci.upper[m], col="red")
94   }else{
95     points(x=c(m,m), y=ci.beta1, pch=15, cex=0.5, col="blue")
96     segments(x0=m, y0=ci.lower[m], x1=m, y1=ci.upper[m], col="blue")
97   }
98 } # for
99 abline(h=2,lty=2)
100
101 #practice2
102 reg.x2 <- lm(WT18 ~ HT18 + x2, data=BGSnew)
103 reg.x3 <- lm(WT18 ~ HT18 + x3, data=BGSnew)
104 #VIF
105 library(car)
106 vif(reg.x2)
107 vif(reg.x3)
108
109 #simulation2
110 M <- 10000
111 n <- 100
112 beta <- c(1, 2, -0.5)
113
114 ci.lower <- ci.upper <- rep(0,M)
115 plot(NULL, xlab="m", ylab="Confidence Interval", xlim=c(1,M), ylim=c(1,3))

```



```

116 set.seed(44)
117
118 ci.lower <- ci.upper <- rep(0, M)
119 count_in <- 0 # カウンタ：期待値含む
120 count_out <- 0 # カウンタ：期待値含まない
121
122 confint(mreg2)
123 for (m in 1:M) { # 文開始for
124   x1 <- runif(n, -3, 3)
125   x2 <- runif(n, -3, 3)
126   error <- rnorm(n, 0, sqrt(5))
127   y <- beta[1] + beta[2]*x1 + beta[3]*x2 + error
128   reg <- lm(y ~ x1 + x2)
129   ci.beta1 <- confint(reg)[2,]
130   ci.lower[m] <- ci.beta1[1]
131   ci.upper[m] <- ci.beta1[2]
132   if(ci.lower[m]>beta[2]|ci.upper[m]<beta[2]){
133     points(x=c(m,m), y=ci.beta1, pch=15, cex=0.5, col="red")
134     segments(x0=m, y0=ci.lower[m], x1=m, y1=ci.upper[m], col="red")
135     count_out <- count_out + 1
136   }else{
137     points(x=c(m,m), y=ci.beta1, pch=15, cex=0.5, col="blue")
138     segments(x0=m, y0=ci.lower[m], x1=m, y1=ci.upper[m], col="blue")
139     count_in <- count_in + 1
140   }
141 } # for
142 abline(h=2,lty=2)
143 cat("真の値を含む回数:", count_in, "\n")
144 cat("真の値を含まない回数:", count_out, "\n")
145 cat("被覆率:", count_in / M, "\n")

```